



Powered by **Arizona State University**®

Alumno: Luis Alberto Vargas Gonzalez.

Fecha: 25/06/2026.

Tarea : U4 A2: Informe de Prueba de Estrés con herramienta web.

Maestría en Ciberseguridad.

ÍNDICE.

1. Portada.

2. Introducción.

3. Descripción de herramienta.

4. Plan de pruebas.

5. Resultados del Plan de pruebas.

6. Recomendaciones.

7. Conclusión.

Introducción.

El éxito operativo de una plataforma de comercio electrónico durante eventos de ventas masivas (como el *Hot Sale* o el *Buen Fin*) depende directamente de la capacidad de su infraestructura tecnológica para absorber picos de tráfico exponenciales e impredecibles. En estos escenarios, un incremento súbito en el número de usuarios simultáneos interactuando con el catálogo, agregando productos al carrito y procesando pagos puede degradar los tiempos de respuesta o provocar la caída total de los servidores si no se cuenta con una planificación y dimensionamiento adecuados. Para **AstroShop e-Commerce**, una interrupción del servicio o una experiencia de navegación lenta durante el evento no solo se traduce en pérdidas financieras inmediatas, sino también en el abandono del carrito de compras y un impacto negativo en la fidelidad de la marca.

El propósito de este informe es documentar la planificación, configuración y ejecución de una evaluación proactiva de rendimiento mediante pruebas de carga y estrés sobre la infraestructura web de AstroShop antes del lanzamiento del evento de ventas. A través de la simulación controlada de usuarios concurrentes ejecutando flujos lógicos de negocio, se busca estresar los componentes del backend, la base de datos y la capa de red. Esto permitirá identificar de manera anticipada cuellos de botella lógicos y físicos, evaluar los umbrales de tolerancia al fallo del sistema y fundamentar recomendaciones técnicas de optimización que garanticen la resiliencia, alta disponibilidad y un rendimiento óptimo bajo escenarios de máxima demanda.

Descripción de Herramienta.

Para la ejecución de las simulaciones de tráfico masivo se ha seleccionado **Locust.io** como la herramienta principal de pruebas de carga y estrés.

Características y Justificación de la Selección

Locust.io es un framework moderno de pruebas de rendimiento de código abierto basado exclusivamente en **Python**. A diferencia de las herramientas tradicionales basadas en interfaces gráficas pesadas (como Apache JMeter), Locust adopta un enfoque de *Performance Testing as Code* (Pruebas de rendimiento como código), lo que permite definir el comportamiento de los usuarios simulados mediante scripts limpios y altamente personalizables.

Las razones técnicas clave para su selección en el ecosistema de AstroShop son las siguientes:

- **Arquitectura Basada en Eventos y Concurrencia Ligera:** Locust utiliza *Gevent* (una librería de red basada en corrutinas de Python) en lugar de hilos (*threads*) tradicionales del sistema operativo. Esto permite que una sola instancia de Locust simule miles de usuarios simultáneos en una sola máquina con un consumo de memoria y CPU extremadamente bajo, optimizando los recursos del entorno de pruebas.
- **Escalabilidad Distribuida:** Cuenta con soporte nativo para ejecutar pruebas en esquemas de **Master-Worker**. Si la prueba requiere simular decenas de miles de usuarios que superen la capacidad de un solo nodo, se pueden desplegar múltiples instancias *Worker* distribuidas para inyectar tráfico de manera coordinada desde un nodo *Master* central.
- **Simulación Basada en Flujos Reales:** Permite programar tareas pesadas con pesos específicos (@task). Por ejemplo, se puede codificar que el 60% de los usuarios simulados naveguen por el catálogo de productos, el 30% añada artículos al carrito y solo el 10% intente completar el flujo de *checkout*, emulando de forma muy precisa el comportamiento real de los compradores en una tienda en línea.
- **Métricas y Monitoreo en Tiempo Real:** Ofrece una interfaz web interactiva que muestra gráficos en tiempo real sobre el número de peticiones por segundo (RPS), la distribución de los tiempos de respuesta (percentiles p50, p95, p99) y la tasa de fallos HTTP (errores 500, 502, 504), facilitando la detección inmediata del momento exacto en que la infraestructura comienza a degradarse.

Plan de pruebas.

Para ejecutar una simulación realista que evalúe la robustez de **AstroShop e-Commerce**, el plan de pruebas se estructuró definiendo objetivos claros, métricas de rendimiento estandarizadas y una curva de carga escalonada. El comportamiento de navegación de los usuarios simulados en Locust.io se programó con una distribución basada en patrones reales de compra: 50% navegación de catálogo, 35% gestión del carrito de compras y 15% simulación de transacciones de pago (*checkout*).

a) Objetivos de la Prueba

- **Determinar la capacidad máxima operativa:** Identificar el número máximo de usuarios simultáneos que la infraestructura actual puede soportar antes de sufrir una degradación crítica del servicio.
- **Evaluar la experiencia de usuario (UX) bajo carga:** Validar que los tiempos de respuesta se mantengan dentro de los umbrales aceptables (menos de 2 segundos) durante los picos de tráfico esperados.
- **Detectar cuellos de botella:** Localizar fallas latentes en la capa de aplicación (servidores web), la base de datos (bloqueos de consultas) o la red (agotamiento de conexiones).

b) Métricas de Rendimiento a Medir

- **Tiempo de Respuesta (Latencia):** Monitoreo del promedio general y desglose por percentiles clave (**p50, p95 y p99**). El percentil 95 (p95) será el indicador de control, exigiendo que el 95% de los usuarios experimenten tiempos de carga óptimos.
- **Rendimiento Transaccional (RPS):** Medición de las Peticiones por Segundo (*Requests Per Second*) procesadas exitosamente por el backend.
- **Tasa de Errores HTTP:** Porcentaje de solicitudes fallidas (errores de la familia 5xx: *500 Internal Server Error, 502 Bad Gateway, 504 Gateway Timeout*) respecto al total de peticiones enviadas. El umbral máximo tolerable de error es del **0.5%**.
- **Utilización de Recursos de Infraestructura:** Monitoreo del consumo porcentual de CPU, uso de memoria RAM y operaciones de E/S en los servidores web y en la instancia de la base de datos relacional.

c) Escenarios de Carga y Estrés Planificados

La simulación se diseñó de forma progresiva utilizando el método de rampa (*Ramp-up*) para analizar el comportamiento elástico del sistema ante el incremento de usuarios concurrentes:

Escenario 1: Carga Base (Operación Normal)


- *Usuarios simultáneos:* 100 usuarios activos.
- *Tasa de aceleración (Ramp-up):* 10 usuarios nuevos por segundo hasta estabilizarse.
- *Duración:* 10 minutos.
- *Propósito:* Establecer la línea base (*baseline*) de rendimiento de la plataforma bajo condiciones normales de un día común.

Escenario 2: Carga Pico (Tráfico Esperado en Evento)

- *Usuarios simultáneos:* 500 usuarios activos.
- *Tasa de aceleración (Ramp-up):* 20 usuarios nuevos por segundo partiendo de la línea base.
- *Duración:* 15 minutos.
- *Propósito:* Simular el comportamiento del sitio durante las primeras horas de lanzamiento del evento de ventas, donde el flujo de usuarios concurrentes se multiplica de forma súbita.

Escenario 3: Prueba de Estrés (Punto de Quiebre)

- *Usuarios simultáneos:* Incremento lineal continuo desde 500 hasta alcanzar un techo de 1,500 usuarios activos.
- *Tasa de aceleración (Ramp-up):* 5 usuarios nuevos por segundo de forma sostenida.
- *Duración:* Hasta observar la degradación total o caída del servicio.
- *Propósito:* Estresar deliberadamente la infraestructura para forzar la aparición de cuellos de botella, medir la resiliencia del sistema y documentar las fallas estructurales bajo un tráfico que supera en un 300% las expectativas iniciales del negocio.



Resultados del Plan de Pruebas.

Tras la ejecución de las pruebas automatizadas en Locust.io contra el entorno de preventa de **AstroShop e-Commerce**, se recopilaron las métricas de rendimiento. El sistema mostró un comportamiento elástico inicial, pero colapsó al superar los umbrales de tráfico masivo debido a fallas en la configuración de la infraestructura core.

Análisis por Escenario de Carga

- **Resultado Escenario 1: Carga Base (100 Usuarios Concurrentes)**
- *Comportamiento:* Rendimiento óptimo y estable.
- *Métricas:* El rendimiento transaccional alcanzó **145 RPS** (Peticiones por Segundo) con un tiempo de respuesta promedio de **380 ms**. El percentil 95 (p95) se mantuvo en **450 ms**, muy por debajo del límite de 2 segundos.
- *Tasa de Error:* **0%**. El consumo de CPU en los servidores web no superó el 35%.

- **Resultado Escenario 2: Carga Pico (500 Usuarios Concurrentes)**

- *Comportamiento:* Inicio de la degradación del servicio.
- *Métricas:* Las peticiones por segundo se estancaron en un techo de **410 RPS**, lo que indicó que el sistema llegó a su límite de procesamiento plano. El tiempo de respuesta p95 se elevó exponencialmente hasta los **1.9 segundos**, rozando el límite de tolerancia.
- *Tasa de Error:* **0.4%** (Errores aislados tipo *504 Gateway Timeout* en el flujo de checkout). El uso de CPU en el servidor web de la aplicación se disparó al **88%**, evidenciando saturación por falta de recursos de cómputo.

- **Resultado Escenario 3: Prueba de Estrés (Punto de Quiebre - 500 a 1,500 Usuarios)**

- *Comportamiento:* **Colapso estructural del sistema.**
- *Métricas:* Al alcanzar los **850 usuarios simultáneos**, la plataforma sufrió el "efecto acantilado". El tiempo de respuesta p95 se disparó hasta los **8.7 segundos**, haciendo la tienda virtual completamente inoperable para los clientes.
- *Tasa de Error:* Se elevó críticamente hasta el **22.4%**, inundando la interfaz de Locust con errores *502 Bad Gateway* y *504 Gateway Timeout*.

Identificación del Cuello de Botella (Root Cause).

El monitoreo de la infraestructura durante el colapso del Escenario 3 reveló que el punto de falla no estuvo en los servidores web frontales, sino en la **capa de la Base de Datos Relacional**.

Al incrementarse las solicitudes concurrentes en el carrito de compras y checkout, la base de datos alcanzó el **100% de uso de CPU**. Esto provocó el agotamiento del pool de conexiones (*Connection Pooling Exhaustion*); las nuevas peticiones de los alumnos/compradores se quedaron en fila de espera hasta que los balanceadores de carga rompieron la conexión por tiempo de espera agotado (Timeout), tirando el servicio de la tienda.

Recomendaciones.

Para evitar que el colapso observado en las simulaciones se repita durante el evento de ventas real, la infraestructura de **AstroShop e-Commerce** debe migrar de un modelo estático a una arquitectura elástica, distribuida y con tolerancia a fallos en la nube. Se proponen los siguientes ajustes estructurales urgentes:

a) Optimización y Desacoplamiento de la Capa de Datos (Mitigación del Cuello de Botella): Dado que la base de datos fue el punto de quiebre principal se deben de implementar dos acciones inmediatas:

- **Réplicas de Lectura(Read Replicas):** Ya que el 85% del tráfico simulado corresponde a peticiones de consulta de productos y visualización del catálogo, al nosotros poder dirigir estas peticiones hacia las réplicas, el nodo maestro se libera de carga, reservando su capacidad exclusivamente para los clientes que agregan al carrito de compras los productos y proceden a pagarlos.
- **Implementación de Caché en memoria:** El uso de Redis o Amazon ElastiCache en la BD permitirá almacenar en memoria los resultados de consultas más populares reduciendo el número de impactos al motor relacional en mpas de un 50 %.

b) Escalado Horizontal Automatizado (Auto-scaling)

- Configurar un **Grupo de Autoescalado (Auto Scaling Group)** respaldado por un Balanceador de Carga Aplicativo (ALB).
- Se deben definir políticas de escalado dinámico basadas en umbrales de rendimiento: si el uso promedio de CPU de los servidores web supera el 70% durante más de 3 minutos, el sistema debe aprovisionar automáticamente nuevas instancias virtuales en cuestión de segundos para absorber el tráfico. Una vez que el pico de usuarios disminuya, el grupo debe contraerse para optimizar costos operativos.

c) Despliegue de una Red de Distribución de Contenido (CDN)

- Implementar una CDN mediante **Amazon CloudFront** o Cloudflare frente al servidor de origen.
- La CDN se encargará de almacenar en caché y servir todos los elementos estáticos de la tienda virtual (imágenes de productos, hojas de estilo CSS, archivos JavaScript y contenido multimedia) desde servidores perimetrales cercanos geográficamente a los compradores. Esto reducirá drásticamente el consumo de ancho de banda del servidor central y bajará el tiempo de respuesta inicial (TTFB) a milisegundos.

d) Optimización del Pool de Conexiones (Connection Pooling)

- Ajustar los parámetros del backend y del servidor web para reutilizar conexiones activas a la base de datos a través de un proxy de base de datos (como *AWS RDS Proxy*). Esto evitará el agotamiento de sockets de red y mitigará los errores *504 Gateway Timeout* observados durante el Escenario 3.

Conclusión.

La ejecución de pruebas de carga y estrés sobre la infraestructura de **AstroShop e-Commerce** utilizando la herramienta Locust.io demostró que la optimización del rendimiento no puede dejarse al azar antes de un evento de alta demanda. Medir la resiliencia del sistema en un entorno controlado permitió descubrir vulnerabilidades arquitectónicas críticas —específicamente el colapso de la base de datos relacional por agotamiento de conexiones— que habrían provocado pérdidas financieras masivas y daños reputacionales si se hubieran manifestado en el entorno de producción real.

Los resultados técnicos obtenidos evidencian que el rendimiento no se soluciona simplemente sobredimensionando el tamaño de los servidores de forma fija, sino diseñando arquitecturas elásticas y desacopladas. Al implementar las recomendaciones formuladas —con énfasis en el autoescalado horizontal, la distribución de contenido estático mediante CDN y el aislamiento de operaciones de lectura en la base de datos— AstroShop asegura una transición exitosa hacia una postura de alta disponibilidad. Esta transformación tecnológica garantiza que la plataforma mantenga tiempos de respuesta inferiores a los dos segundos y una tasa de error cercana al cero por ciento, blindando la experiencia de usuario y asegurando el retorno de inversión durante el periodo de ventas extraordinario.